

Mini Projet - NLP Partie 1**Data Process + Data Visualization**

« L'Afrique de l'Ouest est-elle bien desservie par le transport aérien ? »

1. Présentation du projet

Ce mini projet combine deux compétences du module : le traitement de données avec Pandas (séquences 1 à 7 et 12 du scénario pédagogique) et les principes de visualisation et de storytelling vus dans le support Data Visualization. Il se déroule en deux phases liées : la Phase B s'appuie directement sur les résultats produits en Phase A.

Le projet est volontairement standalone : il ne reprend aucun des cas d'usage du portefeuille CITADEL, afin de garantir un exercice neutre, comparable entre tous les étudiants, et fondé sur une donnée réelle, ouverte et vérifiée.

2. Données

Source ouverte et accessible, mise à jour quotidiennement : OurAirports — base mondiale des aéroports.

URL = "https://raw.githubusercontent.com/davidmeggison/ourairports-data/main/airports.csv"

Colonnes disponibles (extrait pertinent) : ident, name, type, iso_country, latitude_deg, longitude_deg, elevation_ft, scheduled_service.

3. Individualisation des paramètres

Pour garantir que chaque projet repose sur des données et un contexte propres à l'étudiant — et limiter la possibilité de copier une réponse générique produite par un assistant IA — chaque étudiant se voit attribuer automatiquement, à partir de son matricule (fonction de hachage déterministe fournie dans le notebook) :

- une région du monde (sous-ensemble de pays à analyser),
- un scénario de communication (audience et message à défendre en Phase B).

Pool de régions :

Région	Pays (codes ISO)
Afrique de l'Ouest	BF, ML, NE, SN, CI, GH, NG, TG, BJ, GN
Afrique de l'Est	KE, TZ, UG, ET, RW, SO, DJ, BI
Afrique australe	ZA, ZW, ZM, BW, NA, MZ, MW
Amérique centrale	GT, HN, SV, NI, CR, PA, BZ
Asie du Sud-Est	TH, VN, KH, LA, MM, PH, ID, MY
Europe de l'Est	PL, CZ, SK, HU, RO, BG, UA

Pool de scénarios :

Code	Who (audience)	What (message)
A	Comité d'investissement régional (ex. BOAD)	Justifier un investissement dans un pays sous-desservi de l'échantillon
B	Grand public, via un article de blog	Sensibiliser sur les inégalités d'accès au transport aérien
C	Compagnie aérienne low-cost	Identifier une opportunité de marché : un pays sans grand aéroport actif

4. Phase A — Data Process

A.1 — Import

- Charger le CSV directement depuis l'URL avec `pandas.read_csv()`.

A.2 — Prétraitement

- Ne garder que les colonnes utiles et les renommer : ID, airport_name, type, country, lat, long, elevation, service.
- Identifier et traiter les valeurs manquantes de la colonne elevation (stratégie à justifier par écrit).
- Sauvegarder le résultat dans `airports_clean.csv`.

A.3 — Opérations individualisées (sur la région assignée uniquement)

- Extraire les aéroports dont le nom contient un mot-clé au choix (ex. « International »).
- Extraire les aéroports dont le nom commence dans une plage alphabétique au choix.
- Identifier (`nsmallest` / `nlargest`) l'aéroport à l'altitude minimale et maximale de la région.
- Construire une table de synthèse par pays : nombre total d'aéroports, nombre de large_airport, nombre d'aéroports avec service régulier.
- Identifier les pays sans aucun grand aéroport en service régulier (« sous-desservis »).
- Exporter `synthese_pays.csv`.

5. Phase B — Data Visualization

B.1 — Contexte (Who / What / How)

Reformuler avec ses propres mots le scénario assigné : qui est précisément l'audience, quel message ou quelle action est attendue, quel mécanisme de communication (présentation orale, document écrit...) et quel ton adopter.

B.2 — Exploratoire vs Explicatoire

Documenter d'abord ce que l'analyse exploratoire de la table de synthèse révèle, puis choisir un seul message à communiquer (analyse explicative).

B.3 — Storyboard

Structurer la communication en quatre blocs courts : Issue, Démonstration de l'issue, Idée retenue, Recommandation.

B.4 — Choix du graphique

Choisir et justifier un type de graphique adapté à une comparaison de quantités entre catégories (pays). Le bar chart horizontal est recommandé par le cours pour ce type de donnée. Les pie charts, donut charts et graphiques 3D sont interdits — l'étudiant doit pouvoir expliquer pourquoi ces formats seraient inadaptés ici.

B.5 — Decluttering pas à pas

Reproduire la méthode du cours en partant d'un graphique par défaut (« avant »), puis en appliquant successivement : suppression des bordures, nettoyage des axes, labellisation directe des données, usage intentionnel de la couleur (mise en évidence d'un seul pays), et un titre déclaratif portant l'insight plutôt qu'une description neutre.

B.6 — Message final

Conclure en deux à trois phrases répondant explicitement au triplet Who/What/How défini en B.1, en s'appuyant sur le graphique final.

6. Rendu attendu

- Le notebook complété (Jupyter ou Google Colab), code et sorties visibles, exécutable de bout en bout (Restart & Run All).

- Les fichiers airports_clean.csv, synthese_pays.csv, graphique_final.png.
- Un fichier storyboard.md reprenant la section B.3.
- Un dépôt GitHub mini_projet_data_dataviz_partie1, avec un historique de commits incrémental montrant la progression du travail (import → nettoyage → filtres → synthèse → visualisation), et non un commit final unique.

7. Évaluation

L'évaluation porte sur le processus et la compréhension autant que sur le résultat final. Un notebook fonctionnel ne suffit pas : la traçabilité Git, les justifications écrites et la soutenance orale comptent pour 35% de la note, précisément pour vérifier une maîtrise réelle plutôt qu'une simple génération automatique du livrable.

Critère	Poids	Détail
Justesse technique Pandas	20%	Filtres, extraction, gestion des NaN, syntaxe correcte
Cohérence avec les paramètres individualisés	10%	Bon sous-ensemble pays / scénario assigné, respecté de bout en bout
Justifications Markdown (exploratoire)	10%	Lecture critique des données obtenues, pas de simple description
Contexte Who/What/How	10%	Cohérence audience / message / mécanisme, reformulation personnelle
Choix du graphique + justification	15%	Pertinence du type de graphique, absence de pie/donut/3D, argumentation
Application du decluttering (avant/après visible)	15%	Les étapes du cours reproduites et justifiées, pas juste copiées
Qualité du titre déclaratif et du message final	10%	Le titre porte l'insight, pas une description neutre
Soutenance / traçabilité Git	10%	Capacité à expliquer et modifier le code en direct ; historique de commits incrémental